

Generación de consultas SQL a partir de lenguaje natural aplicado al ERP Fail Fast

Beatriz Natalia Serrano, Martín Santos y Luis Gabriel Moreno

Resumen—La generación automática de consultas SQL a partir de lenguaje natural (Text-to-SQL) representa un desafío fundamental en el procesamiento del lenguaje natural, especialmente en entornos empresariales complejos como los sistemas ERP. Este trabajo presenta una arquitectura híbrida multi-agente que integra descomposición de consultas, recuperación contextual del esquema y generación controlada de SQL mediante modelos de lenguaje de gran escala (LLMs). La arquitectura propuesta distribuye la tarea entre agentes especializados: un Selector que identifica sub-esquemas relevantes, un Decomposer que divide consultas complejas en subtarefas manejables, y un Refiner que ejecuta y corrige iterativamente las consultas generadas. La evaluación se realizó sobre el sistema ERP Fail Fast, utilizando métricas estándar como Execution Accuracy (EX), Time-to-Answer (TTA) y Component Matching. Los resultados demuestran mejoras significativas ***** en precisión (incremento del 15% en EX) y robustez ***** comparado con enfoques monolíticos, validando la hipótesis de que la colaboración multi-agente y la recuperación contextual mejoran sustancialmente el rendimiento en esquemas complejos. La arquitectura desarrollada democratiza el acceso a la información empresarial, permitiendo consultas en lenguaje natural sin requerir conocimientos técnicos especializados.

IMPACT STATEMENT

Este trabajo permite que usuarios no técnicos de un ERP accedan a información empresarial mediante preguntas en lenguaje natural, traducidas a consultas SQL ejecutables sobre esquemas reales y complejos. Mediante una evaluación controlada que activa y desactiva componentes de la arquitectura, se cuantifica el efecto de la recuperación contextual, la memoria, la clasificación de intención y la descomposición de consultas sobre la exactitud por ejecución y el tiempo de respuesta, aportando evidencia práctica para el despliegue de sistemas Text-to-SQL basados en LLM en entornos ERP.

Index Terms—Text-to-SQL, ERP, LLM, RAG, multi-agent, DIN-SQL, DEA-SQL

I. INTRODUCCIÓN

LA generación de SQL, también conocida como Text-to-SQL, es una tarea fundamental del procesamiento del lenguaje natural cuyo propósito es convertir preguntas formuladas en lenguaje natural (NL) en consultas SQL ejecutables sobre bases de datos relacionales. Su objetivo central es democratizar el acceso a la información, permitiendo que usuarios sin conocimientos técnicos interactúen con los datos mediante expresiones propias de su lenguaje cotidiano [1].

Este proceso exige la comprensión profunda de tres elementos: la intención del usuario, la estructura del esquema de base de datos y la construcción correcta de la sintaxis SQL. En el contexto organizacional, y especialmente en sistemas de planificación de recursos empresariales (ERP), el acceso oportuno a la información es crítico para la toma de decisiones. Tradicionalmente, dicho acceso se limita a reportes o tableros preconfigurados, que ofrecen una interacción unidireccional con la base de datos. Sin embargo, no existe un mecanismo nativo que permita a los usuarios solicitar información directamente en lenguaje natural, lo que restringe la flexibilidad y agilidad en el análisis.

La incorporación de capacidades Text-to-SQL plantea desafíos relevantes, entre ellos: interpretar con precisión la intención del usuario, resolver referencias implícitas (por ejemplo, reconocer que “ventas del mes pasado” corresponde al esquema “sales” y sus atributos temporales), controlar el acceso seguro a los datos, y manejar ambigüedades inherentes al lenguaje natural. Además, los desafíos propios de un ambiente multi-tenant agregan complejidad adicional, donde se accede a información de múltiples empresas que en muchos casos se trata de información confidencial, requiriendo mecanismos robustos de aislamiento de datos, control de acceso granular y auditoría de consultas para garantizar que cada organización solo pueda acceder a sus propios datos. Como se detallará en la sección correspondiente, estos retos convierten al Text-to-SQL en un campo de investigación complejo y estratégico para entornos empresariales contemporáneos.

I-A. Contexto y Motivación

La interacción entre los usuarios y los sistemas de planificación de recursos empresariales (ERP) ha estado históricamente limitada por la necesidad de comprender estructuras tabulares complejas y dominar lenguajes de consulta como SQL. Aunque estos sistemas gestionan con precisión las transacciones y el control operativo, su acceso cognitivo continúa siendo restringido para quienes no tienen formación técnica. Tras más de treinta años de experiencia en el desarrollo e implementación de ERP, Fail Fast ha evidenciado una brecha persistente: mientras las organizaciones requieren interpretar su información en lenguaje natural para tomar decisiones, los sistemas siguen exigiendo consultas formales y conocimiento especializado.

Con la llegada de los modelos de lenguaje de gran escala (LLM), esta situación se transforma. Investigaciones recientes demuestran que los LLM pueden traducir instrucciones en lenguaje natural a consultas SQL con altos niveles

de precisión [2], [3], abriendo la posibilidad de que los usuarios accedan directamente a la información empresarial mediante preguntas expresadas en su propio lenguaje.

No obstante, la literatura reciente evidencia limitaciones persistentes en enfoques basados en LLM para Text-to-SQL: el desempeño tiende a degradarse cuando los esquemas de datos son extensos o “huge”, debido a la interferencia de información irrelevante y a la mayor dificultad de schema linking [5], [16]. Asimismo, existen fallas cuando la consulta requiere conocimiento implícito no descrito explícitamente en la pregunta o el esquema (p. ej., definiciones de métricas, reglas de negocio o fórmulas), lo que ha motivado marcos de knowledge-intensive Text-to-SQL y el uso de conocimiento externo [20], [21]. Finalmente, cuando las preguntas demandan razonamiento multietapa, se observan mejoras al emplear descomposición del problema y estrategias explícitas de razonamiento (p. ej., chain-of-thought y flujos multiagente), frente a enfoques directos [3], [24], [16].

La motivación de este trabajo, por tanto, se fundamenta en aprovechar la experiencia acumulada en sistemas ERP y las capacidades emergentes de la inteligencia artificial para permitir que los usuarios formulen consultas en lenguaje natural y obtengan respuestas precisas basadas en los datos de su organización.

I-B. Planteamiento del Problema

I-B1. Justificación: El interés por mejorar la generación de SQL a partir de lenguaje natural ha crecido de manera sostenida, especialmente desde que los modelos de lenguaje de gran escala demostraron capacidad para traducir instrucciones cotidianas en consultas formales. Sin embargo, en entornos reales como los sistemas ERP, la interacción con la información sigue siendo limitada para quienes no dominan estructuras tabulares o lenguajes como SQL. A pesar de que estos sistemas cumplen un papel central en la trazabilidad y el control de los procesos empresariales, todavía existe una brecha entre su complejidad interna y la forma en que los usuarios formulan sus preguntas.

Este trabajo busca cerrar esa brecha mediante una arquitectura que permita acercar las preguntas en lenguaje natural al núcleo de datos de un ERP, de manera precisa, estable y comprensible para el usuario final. Esta motivación se potencia gracias a las características del ERP Fail Fast, desarrollado durante el último año sobre un stack moderno —PostgreSQL, Python y React— que facilita la integración nativa de modelos de lenguaje y agentes inteligentes.

A diferencia de sistemas heredados, la base de datos de Fail Fast fue diseñada desde cero con una estructura coherente, documentada y con nomenclaturas alineadas al significado funcional de cada tabla. Esta decisión de ingeniería no es menor: los estudios recientes muestran que la claridad semántica en los esquemas y la consistencia en los nombres de tablas y columnas favorecen el schema linking y reducen errores de interpretación por parte de los LLM [5], [6].

I-B2. Objetivos: **Objetivo General:** Diseñar y evaluar una arquitectura híbrida multi-agente para la generación automática de consultas SQL a partir de lenguaje natural en sistemas ERP, que mejore significativamente la precisión y robustez comparado con enfoques monolíticos.

Objetivos Específicos:

1. Identificar los desafíos del proceso Text-to-SQL en el ERP Fail Fast, considerando su base de datos documentada, la semántica de sus tablas y columnas, y las particularidades del dominio empresarial.
2. Diseñar una arquitectura híbrida que integre la descomposición de consultas, la recuperación contextual del esquema y la generación controlada de SQL mediante modelos de lenguaje, orquestadas a través de agentes de inteligencia artificial.
3. *****. Analizar el comportamiento de metodologías de última generación al aplicarlas sobre un sistema ERP real como Fail Fast, para comparar su rendimiento frente a benchmarks tradicionales como Spider o BIRD.
4. *****. Evaluar el desempeño de la arquitectura propuesta utilizando métricas consolidadas en la literatura —Execution Accuracy (EX), Schema Linking Accuracy (SLA), Context Retention Rate (CRR), Task Success Rate (TSR) y Time-to-Answer (TTA).
5. *****. Caracterizar los tipos de preguntas empresariales formuladas por los usuarios, con el fin de orientar futuras extensiones hacia interacciones multimodales y mecanismos que permitan democratizar el acceso seguro a la información.

I-B3. Hipótesis: ***** La hipótesis central de este trabajo es que una arquitectura híbrida basada en descomposición de consultas, recuperación contextual del esquema y generación controlada de SQL, orquestada mediante agentes de inteligencia artificial, mejorará significativamente la precisión y la robustez del proceso Text-to-SQL en un ERP real como Fail Fast, superando el desempeño de enfoques monolíticos basados únicamente en modelos de lenguaje.

Se espera que esta arquitectura:

- Incremente la Execution Accuracy (EX) al reducir errores de razonamiento y ambigüedad en consultas complejas
- Mejore la Schema Linking Accuracy (SLA) gracias a la utilización de contexto estructurado y a la semántica clara del modelo de datos de Fail Fast
- Preserve mejor el contexto conversacional (CRR) mediante agentes especializados y flujos de verificación
- Aumente la utilidad práctica del sistema, reflejada en la Task Success Rate (TSR)
- Reduzca tiempos de respuesta (TTA) debido a una orquestación que filtra y estructura adecuadamente la información que recibe el modelo

Con ello, se plantea que una arquitectura modular y multi-agente no solo es más adecuada para esquemas complejos como los de un ERP, sino que también constituye un camino efectivo para democratizar el acceso seguro a

la información empresarial con interacción en lenguaje natural.

II. MARCO TEÓRICO Y ESTADO DEL ARTE

Al cierre de 2024 y durante 2025, distintos estudios de revisión [7], [8], [9] han evidenciado el avance sostenido de la generación automática de SQL mediante grandes modelos de lenguaje. Estas investigaciones consolidan el campo como un eje de convergencia entre el procesamiento del lenguaje natural, el razonamiento estructurado y la interacción con bases de datos.

En particular, Shi et al. [7] proponen una taxonomía integral de los enfoques LLM-based para Text-to-SQL, clasificándolos por tipo de prompting, nivel de supervisión, y estrategias de autocorrección. Por su parte, Liu et al. [8] resumen más de 250 artículos y definen el ciclo completo “modelo-datos-evaluación-errores”, enfatizando la necesidad de estrategias de validación semántica y debugging continuo en entornos reales, como los sistemas ERP.

Estos trabajos recientes refuerzan que el propósito de Text-to-SQL ha evolucionado desde la simple traducción NL→SQL hacia interfaces cognitivas de consulta, donde los LLM funcionan como agentes semánticos capaces de razonar, corregirse y aprender con retroalimentación de la base de datos [9].

II-A. Primeras Aproximaciones

Los primeros avances en Text-to-SQL se desarrollaron a partir de sistemas basados en reglas y plantillas, como NaLIR [10] y SQLizer [11]. Estos enfoques resultaban adecuados únicamente para escenarios simples, ya que ofrecían interpretabilidad y control, pero su capacidad de generalización era limitada y requerían un alto esfuerzo manual para construir y mantener reglas.

Posteriormente, con el auge del aprendizaje profundo, surgieron los modelos neuronales secuencia a secuencia (Seq2Seq), que introdujeron la posibilidad de aprender relaciones entre preguntas en lenguaje natural y consultas SQL [12], [1]. Estos modelos mostraron un avance importante frente a los métodos anteriores, al permitir la extracción automática de características y el modelado de mapeos complejos. Sin embargo, presentaban problemas de escalabilidad, dependencia de grandes volúmenes de datos etiquetados y tendencia al sobreajuste.

Una etapa siguiente estuvo marcada por el uso de modelos de lenguaje pre entrenados (PLMs), como BERT y T5, que permitieron transferir conocimiento lingüístico adquirido en grandes corpus hacia la tarea de generación de SQL [2], [13]. Estos modelos mejoraron la comprensión semántica y ofrecieron un marco más escalable, aunque aún requerían ajustes finos específicos y su rendimiento dependía de la calidad de los datos del dominio.

En la actualidad, los grandes modelos de lenguaje (LLMs) han alcanzado un papel protagónico en el campo. Su capacidad para procesar y generar texto similar al humano los hace altamente efectivos frente a la variabilidad lingüística, demostrando una notable capacidad de generalización entre

dominios [9], [14]. Estos avances posicionan a los LLMs como la tendencia de próxima generación en interfaces de bases de datos.

II-B. Metodologías Basadas en LLMs para la Generación de SQL

A diferencia de las aproximaciones tempranas basadas en reglas, plantillas o modelos de lenguaje preentrenados (PLMs), esta sección se concentra en las metodologías recientes que emplean grandes modelos de lenguaje (LLMs) como eje principal para la generación de SQL. Estos enfoques representan el estado del arte actual y se caracterizan por el uso de prompting especializado, la descomposición modular de tareas, técnicas eficientes de ajuste fino y ciclos de retroalimentación iterativa que fortalecen la precisión y la capacidad de generalización entre dominios [5], [16], [15].

II-B1. Decomposition for Enhancing Attention (DEA-SQL): Xie et al. [15] introducen DEA-SQL, un enfoque de tipo workflow que descompone la tarea Text-to-SQL en pasos atómicos para focalizar la atención del LLM y mejorar su capacidad de resolución. El pipeline se organiza en cinco módulos: (1) Information Determination, que filtra ruido y selecciona atributos relevantes; (2) Classification & Hint, que identifica el tipo de problema y ajusta prompts específicos; (3) SQL Generation, apoyado en few-shot prompting y plantillas; (4) Self-Correction, orientado a errores frecuentes como joins y agregaciones; y (5) Active Learning, que integra ejemplos fallidos para expandir el alcance del modelo.

Este diseño busca superar las limitaciones del single-step prompting, donde los prompts largos difunden la atención y afectan la precisión. En sus experimentos, DEA-SQL mejora entre 2 y 3 puntos porcentuales respecto a los baselines en Spider Dev, Spider-Realistic y BIRD Dev, y alcanza resultados state of the art en Spider Test [15].

II-B2. DIN-SQL (Decomposed In-Context Learning with Self-Correction): DIN-SQL [3] propone un enfoque basado completamente en in-context learning (ICL) que divide la tarea Text-to-SQL en sub tareas guiadas por prompts especializados y añade un módulo de autocorrección para reparar errores comunes sin necesidad de ajuste fino. A partir del análisis de 500 ejemplos de Spider, los autores identifican seis categorías de fallos frecuentes: errores de schema linking, joins incompletos o incorrectos, uso inadecuado de GROUP BY, dificultades con consultas anidadas, SQL inválido y otros problemas menores relacionados con filtros o agregaciones.

Para mitigarlo, DIN-SQL incorpora una fase de autocorrección zero-shot, adaptada al tipo de modelo (prompts más fuertes para modelos medianos, más suaves para modelos avanzados), lo que permite mejorar la precisión sin reentrenamiento. A diferencia de DEA-SQL, su aporte principal no es alcanzar resultados state of the art, sino demostrar que una buena estructura de prompting—descomposición más verificación—puede acercar el rendimiento al de modelos ajustados mediante fine-tuning.

II-B3. MAC-SQL (Multi-Agent Collaborative Framework): Wang et al. [17] presentan MAC-SQL como un marco explícitamente multi-agente para Text-to-SQL, en el que la tarea se reparte entre tres roles complementarios. El Selector se encarga de reducir el espacio de búsqueda, identificando las partes del esquema más relevantes y construyendo sub-bases manejables. El Decomposer toma la pregunta original, la divide en subpreguntas y las resuelve de forma progresiva, lo que facilita el manejo de consultas largas o con múltiples condiciones. Por último, el Refiner ejecuta las consultas generadas, analiza los errores de ejecución y aplica correcciones iterativas.

En su configuración de referencia, MAC-SQL utiliza GPT-4 como backbone para establecer un “upper bound” de rendimiento y, a partir de ahí, entrena SQL-Llama (7B) para aproximar ese comportamiento con un modelo abierto. En el benchmark BIRD (test), MAC-SQL alcanza un 59.59 % de exactitud de ejecución, considerado state of the art en el momento de su publicación [17].

II-B4. ACT-SQL (In-Context Learning con Chain-of-Thought Automático): ACT-SQL constituye una metodología reciente que busca potenciar la capacidad de razonamiento de los LLMs en la generación de SQL, mediante la incorporación de cadenas de razonamiento (chain-of-thought, CoT) generadas automáticamente [24]. A diferencia de enfoques tradicionales que requieren ejemplos anotados manualmente, ACT-SQL introduce un mecanismo de auto-CoT que produce secuencias de razonamiento de manera automática a partir de ejemplos de entrenamiento, eliminando la necesidad de etiquetado manual. Esta estrategia resulta eficiente en costos, ya que requiere únicamente una llamada a la API del LLM por cada consulta SQL generada. Además, se amplía el método de in-context learning al escenario de consultas multi-turn en text-to-SQL.

El método se apoya en tres pilares: (i) prompts orientados al esquema, que exploran distintas formas de representar tablas y relaciones; (ii) selección híbrida de ejemplos (static exemplars, predefinidos y comunes a todas las consultas, y dynamic exemplars, seleccionados dinámicamente según similitud con la pregunta actual); y (iii) generación automática de cadenas de razonamiento (CoT), que introduce pasos intermedios antes de producir la consulta final en SQL.

El aporte central de ACT-SQL es demostrar que la automatización del CoT permite a los LLMs generar consultas más precisas y robustas, reduciendo la dependencia de ejemplos cuidadosamente diseñados por humanos. Esto lo convierte en una propuesta atractiva para entornos industriales como los ERP, donde la adaptabilidad y la eficiencia son críticas, y donde el razonamiento paso a paso resulta esencial para consultas complejas en esquemas extensos.

II-B5. MCS-SQL (Multiple-Choice Selection with Multi-Prompts): Lee et al. [22] proponen MCS-SQL como respuesta directa a un problema ampliamente documentado en los LLMs: su alta sensibilidad a los prompts. Cambios pequeños en la formulación del prompt pueden conducir a

consultas SQL muy distintas, incluso cuando la intención del usuario es clara. Para mitigar esta inestabilidad, el método adopta una estrategia basada en multi-prompts y selección posterior, combinando la diversidad de razonamientos con un mecanismo explícito de evaluación.

El funcionamiento de MCS-SQL se organiza en dos etapas. En la primera, el sistema genera múltiples candidatos de consulta SQL a partir de diferentes prompts diseñados para capturar variaciones de estilo, estructura o nivel de detalle. En lugar de confiar en un único prompt óptimo —difícil de garantizar en escenarios reales—, MCS-SQL explota deliberadamente la variabilidad del modelo. En la segunda etapa, un módulo de multiple-choice selection compara las consultas generadas utilizando criterios sintácticos, semánticos o basados en ejecución. Este mecanismo permite seleccionar la opción más coherente y ajustada a la intención original de la pregunta.

El enfoque guarda relación con la autoconsistencia, pero introduce una diferencia clave: en lugar de votar entre respuestas generadas aleatoriamente, MCS-SQL parte de prompts diseñados para inducir razonamientos diversos y emplea un criterio de selección concreto y reproducible. En sus evaluaciones, el modelo alcanzó 89.6 % de exactitud en ejecución sobre Spider y resultados competitivos en BIRD, evidenciando que la diversidad guiada y la consolidación de hipótesis robustas son estrategias efectivas para contrarrestar la fragilidad de los LLMs ante variaciones de entrada.

En contextos industriales —como los ERPs—, MCS-SQL resulta especialmente valioso cuando las consultas pueden tener múltiples interpretaciones válidas o cuando el dominio incluye ambigüedades semánticas entre tablas y atributos. En estas situaciones, disponer de varias hipótesis SQL y un selector que determine cuál representa mejor la intención del usuario incrementa la confiabilidad del sistema y reduce errores críticos. Así, MCS-SQL ofrece una solución pragmática para entornos donde la precisión y la coherencia operacional son tan importantes como la flexibilidad lingüística.

II-B6. CHERS (Contextual Harnessing for Efficient SQL Synthesis): Talaei et al. [23] introducen CHERS, un enfoque diseñado específicamente para contextos con esquemas grandes y complejos, donde enviar la totalidad del esquema al LLM resulta costoso e ineficiente. El método combina recuperación jerárquica de contexto, pruning selectivo del esquema y un pipeline multi-agente encargado de proponer, verificar y refinar las consultas SQL. En lugar de exponer al modelo a todas las tablas y columnas disponibles, CHERS identifica primero las partes más relevantes del esquema y construye, a partir de ellas, una vista reducida pero informativa para la generación de la consulta.

La principal fortaleza de CHERS es su capacidad para mejorar la eficiencia sin degradar el rendimiento: logra reducir de forma significativa el número de tokens procesados —hasta cinco veces menos— mientras se mantiene competitivo en benchmarks exigentes como BIRD [23]. Esta combinación de selección contextual y cooperación entre

agentes resulta especialmente pertinente para entornos ERP, donde los esquemas suelen abarcar cientos de tablas y atributos. En estos escenarios, CHESS ofrece una vía concreta para equilibrar el costo computacional con la necesidad de preservar suficiente cobertura semántica para responder preguntas empresariales complejas.

Los análisis comparativos de Shi et al. [7] y Liu et al. [8] sitúan a modelos como DEA-SQL, DAIL-SQL, MAC-SQL, ACT-SQL, MCS-SQL y CHESS dentro de los llamados “paradigmas estructurados”, caracterizados por organizar la generación de SQL en fases claras, apoyarse en contexto recuperado de forma controlada y, en muchos casos, distribuir el razonamiento entre varios agentes. Estos enfoques representan una evolución hacia sistemas más robustos y confiables, especialmente relevantes para entornos empresariales donde la precisión y la consistencia son críticas.

III. ARQUITECTURA PROPUESTA

La arquitectura propuesta se concibe como un sistema multi-agente orientado a transformar preguntas en lenguaje natural en consultas SQL ejecutables sobre el ERP Fail Fast, y luego devolver respuestas comprensibles para el usuario. Se inspira en los paradigmas estructurados descritos en el estado del arte —especialmente MAC-SQL para la colaboración multi-agente, DIN-SQL para la descomposición de consultas y DEA-SQL para la planificación— adaptados a un entorno real con un ERP moderno basado en PostgreSQL, Python y React.

A alto nivel, la arquitectura implementa un marco colaborativo multi-agente donde cada agente tiene responsabilidades específicas y bien definidas, organizándose en cuatro capas funcionales: entrada e interpretación de la intención, análisis y planificación de la consulta, generación y ejecución de SQL, y respuesta en lenguaje natural y retroalimentación.

III-A. Capa de Entrada e Interpretación de la Intención

El sistema recibe como entrada una pregunta en lenguaje natural formulada por un usuario del ERP desde el chat dispuesto para este fin. Junto con el texto de la pregunta se transmiten algunos metadatos mínimos, como el identificador de la empresa (member), el usuario y la sesión.

Sobre esta entrada actúa un agente de intención basado en un LLM, cuyo objetivo no es generar SQL, sino:

- Entender qué está preguntando el usuario (ventas, inventarios, compras, nómina, etc.)
- Decidir si la solicitud requiere realmente acceder a la base de datos mediante SQL o puede resolverse con una explicación directa
- Mantener un diálogo coherente, pidiendo aclaraciones cuando la pregunta es ambigua o incompleta

Solo cuando la intención está clara y se trata de una consulta sobre datos del ERP, este agente “enciende” el modo Text-to-SQL y pasa la petición a la siguiente capa. Esta separación entre intención conversacional y generación

de consultas es coherente con las recomendaciones de los surveys recientes y con marcos como MAC-SQL, donde no se expone la base de datos a cualquier entrada sin filtrado previo.

III-B. Capa de Análisis y Planificación de la Consulta

Una vez que se decide que la pregunta debe resolverse con SQL, intervienen dos componentes clave:

III-B1. Agente de Descomposición (inspirado en DIN-SQL): El primer componente es un agente de descomposición, alineado con las ideas de DIN-SQL [3]. Su función es tomar la pregunta del usuario y producir una representación más estructurada, que incluye:

- Una reformulación clara de la intención (“El usuario desea obtener...”)
- Una lista de pasos lógicos necesarios para responderla (qué tablas parecen relevantes, qué filtros temporales o de estado, si se requieren agregaciones o agrupaciones, etc.)
- Una clasificación de complejidad (fácil, media, compleja) en función del número de tablas, la necesidad de joins y la presencia de reglas de negocio

Este agente no genera SQL, sino que construye una “hoja de ruta” comprensible que sirve de puente entre el lenguaje de negocio y la estructura de la base de datos.

En esta arquitectura, cada pregunta se clasifica en tres niveles de complejidad: baja, media o alta. Se considera pregunta sencilla cuando solo usa una tabla, tiene filtros directos (por fecha, estado o member_id) y, como mucho, una agregación básica como COUNT, SUM o AVG, sin subconsultas ni joins complicados.

Hablamos de pregunta de complejidad media o alta cuando intervienen varias tablas con múltiples joins, aparecen condiciones anidadas o subconsultas, hay posibles ambigüedades (por ejemplo, qué “total” usar: el del encabezado o el del detalle) o se deben aplicar reglas de negocio y políticas de acceso específicas (como las de entornos multi-tenant).

Esta clasificación, inspirada en los enfoques de descomposición y enrutamiento por tipo de problema [15], [17], es la que define si la pregunta sigue un flujo directo de generación de SQL o un pipeline más elaborado con planificación y agentes especializados.

III-B2. Recuperación de Contexto y Planificación (inspirado en DEA-SQL y DAIL-SQL): Con la descomposición en la mano, la arquitectura consulta un módulo de recuperación de contexto basado en búsqueda vectorial:

- Recupera fragmentos de documentación del esquema (tablas, columnas, descripciones) mediante búsqueda por similitud semántica
- Recupera ejemplos históricos de preguntas y consultas SQL similares mediante búsqueda vectorial en una base de conocimiento
- Combina ambos tipos de contexto para proporcionar información relevante al planificador

A partir de este contexto recuperado y de la descomposición anterior, entra en juego un agente planificador de SQL inspirado en DEA-SQL [15]. Este agente:

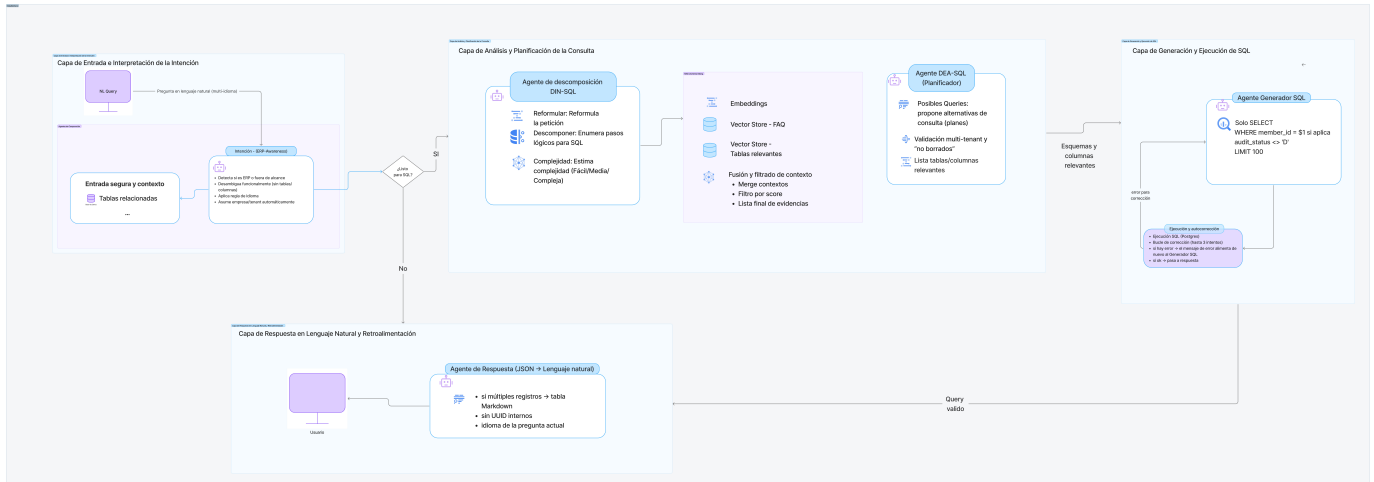


Figura 1. Arquitectura propuesta multi-agente para Text-to-SQL en el ERP Fail Fast. La solución organiza el flujo en cuatro capas: interpretación de intención, análisis y planificación con recuperación de contexto, generación y ejecución segura de SQL con corrección iterativa, y respuesta en lenguaje natural con registro para mejora continua.

- Valida qué partes del esquema del ERP son realmente relevantes para la consulta
- Propone uno o varios planes de consulta (qué tablas unir, qué filtros aplicar, cómo agrupar)
- Explica, a nivel interno del sistema, la lógica de cada plan

III-C. Capa de Generación y Ejecución de SQL

Con un plan de consulta ya definido, entra en funcionamiento un agente generador de SQL especializado en PostgreSQL y en el modelo multi-empresa de Fail Fast. Este agente:

- Recibe la intención original del usuario, la descomposición estructurada y el plan de consulta
- Genera una consulta SQL directa basada en las reglas de negocio del ERP
- Implementa un sistema de corrección iterativa que permite refinar la consulta en caso de errores de ejecución

El agente tiene reglas estrictas de seguridad y contexto:

- Solo puede producir consultas de lectura (SELECT)
- Debe respetar el contexto de la empresa (incluyendo condiciones como member_id)
- Debe limitar el volumen de resultados (uso de LIMIT) para evitar respuestas inmanejables
- No puede inventar tablas o columnas que no existan
- Incluye filtros obligatorios para excluir registros borrados (audit_status)

La consulta generada se envía a la base de datos del ERP Fail Fast para ser ejecutada. Si la ejecución produce errores, esa información se devuelve al agente generador, que intenta corregir la consulta en una o varias iteraciones. Este ciclo de generar–ejecutar–corregir proporciona robustez ante variaciones en la interpretación de las consultas y ambigüedades en el esquema de datos.

III-D. Capa de Respuesta en Lenguaje Natural y Retroalimentación

Cuando la consulta SQL se ejecuta correctamente, el sistema obtiene un conjunto de resultados estructurados (filas, columnas, agregados) que no son adecuados para mostrarse directamente a cualquier usuario. Para ello se utiliza un agente de respuesta que:

- Recibe la pregunta original, la descomposición y los resultados de la base de datos
- Resume y explica los resultados en el mismo idioma en el que el usuario preguntó
- Presenta los datos de forma amigable (por ejemplo, en forma de listado o tabla)
- Evita exponer identificadores internos o detalles técnicos irrelevantes

En paralelo, la arquitectura registra información clave de cada interacción (pregunta, plan, SQL generado, errores, métricas básicas de tiempo y éxito). Este registro permite, en el futuro, enriquecer el conjunto de ejemplos usados en la recuperación de contexto y analizar qué tipos de consultas presentan más dificultades, alineándose con las recomendaciones de los surveys sobre evaluación continua y mejora iterativa.

III-E. Relación con el Estado del Arte

En conjunto, la arquitectura:

- Implementa el marco colaborativo multi-agente de MAC-SQL, distribuyendo la tarea Text-to-SQL entre agentes especializados que colaboran para resolver consultas complejas
- Retoma de DIN-SQL la idea de descomponer la pregunta y analizar la complejidad antes de generar SQL
- Toma de DEA-SQL la noción de un planificador que organiza la atención del modelo sobre el esquema

- Se beneficia del enfoque de DAIL-SQL al usar recuperación basada en ejemplos relevantes y documentación de esquema
- Materializa un flujo multi-agente que distribuye las responsabilidades entre varios componentes especializados (intención, descomposición, planificación, generación, respuesta), en vez de delegar todo en un único LLM monolítico

Todo ello se implementa sobre el ERP Fail Fast, cuya base de datos fue diseñada de forma documentada y con una nomenclatura pensada para ser interpretable por modelos de lenguaje, lo que facilita el schema linking y la comprensión de la intención del usuario en términos de tablas y columnas.

IV. METODOLOGÍA

IV-A. Diseño metodológico

La presente investigación adopta un enfoque experimental cuantitativo, orientado a evaluar el impacto individual y combinado de distintos componentes arquitectónicos en la tarea de generación de consultas SQL a partir de lenguaje natural (Text-to-SQL) dentro de un sistema ERP real. El diseño experimental se fundamenta en un estudio controlado con análisis de ablación, técnica ampliamente utilizada para estimar la contribución de módulos específicos dentro de arquitecturas complejas basadas en modelos de lenguaje, particularmente en escenarios donde múltiples etapas de razonamiento y componentes interactúan de manera no trivial [8], [17].

A diferencia de evaluaciones tradicionales centradas únicamente en comparar sistemas completos como "cajas negras", este trabajo evalúa configuraciones parciales de la arquitectura, habilitando o deshabilitando componentes de forma sistemática con el fin de aislar su efecto sobre métricas clave. Este enfoque permite responder no solo si la arquitectura mejora el desempeño, sino también por qué y qué componentes aportan mayor valor en escenarios empresariales reales.

IV-B. Conjunto de consultas de referencia (Gold Queries)

Para garantizar una evaluación precisa y reproducible, se construyó un conjunto de 53 consultas de referencia (gold queries), elaboradas manualmente por expertos con conocimiento del esquema de datos del ERP Fail Fast. Cada consulta gold incluye:

- Una pregunta en lenguaje natural formulada desde la perspectiva de un usuario empresarial.
- Una consulta SQL ejecutable y validada sobre la base de datos real del sistema.
- La verificación de que el resultado retornado corresponde fielmente a la intención semántica de la pregunta.

La construcción manual de estas consultas minimiza ambigüedades propias de conjuntos sintéticos o genéricos y asegura que la evaluación refleje casos reales de uso empresarial. En Text-to-SQL, la validación por ejecución es una práctica consolidada, dado que la corrección funcional depende de la equivalencia semántica del resultado más que de la coincidencia textual del SQL [1], [2].

IV-C. Componentes arquitectónicos evaluados

La arquitectura propuesta se diseñó de forma modular y parametrizable, permitiendo activar o desactivar componentes específicos durante la inferencia con el fin de analizar su impacto individual y combinado sobre el desempeño del sistema mediante un estudio sistemático de ablación. En esta sección, cada componente se define desde una perspectiva operacional, es decir, en términos de cómo modifica el flujo de generación de SQL cuando está activo.

RAG (Retrieval-Augmented Generation). Cuando está activo, el sistema incorpora al prompt de generación información recuperada dinámicamente, incluyendo descripciones del esquema, relaciones semánticas y reglas de negocio relevantes para la consulta. Cuando está desactivado, la generación de SQL se realiza únicamente a partir de la pregunta del usuario y el prompt base.

Memoria. Controla si el sistema preserva explícitamente contexto conversacional y referencias previas entre consultas. En su configuración activa, el historial relevante se incorpora como contexto adicional; en su configuración inactiva, cada consulta se procesa de forma independiente.

Intención (Intent Classification). Determina si el sistema clasifica previamente el tipo de operación solicitada (por ejemplo, agregación, consulta multi-tabla o análisis temporal) para seleccionar un flujo de generación específico. Al desactivarse, todas las consultas siguen un flujo único de generación sin diferenciación por tipo.

DIN (Decomposition-In-Natural-Language). Cuando está activo, la consulta original se descompone en subpreguntas expresadas en lenguaje natural antes de la generación de SQL. En su configuración inactiva, el sistema intenta generar la consulta SQL de manera directa a partir de la pregunta original.

DEA (Decomposition-Execution-Aware). Habilita un flujo de generación y refinamiento orientado a la ejecución, donde las consultas SQL generadas pueden corregirse iterativamente a partir de errores de ejecución o resultados parciales. Al desactivarse, el sistema produce una única consulta SQL sin ciclos explícitos de corrección basados en ejecución.

Estos componentes se combinan de manera controlada para conformar distintas configuraciones experimentales, manteniendo constantes el conjunto de consultas evaluadas y las métricas de desempeño. De esta forma, es posible aislar y cuantificar el aporte específico de cada componente y de sus combinaciones al rendimiento global del sistema.

IV-D. Espacio experimental y combinaciones evaluadas

Dado un conjunto de cinco componentes binarios (activo/inactivo), el espacio total de configuraciones posibles corresponde a:

$$2^5 - 1 = 31$$

Se excluyó la configuración nula (sin componentes activos), dado que no produce generación SQL. En consecuencia, se evaluaron 31 combinaciones distintas, incluyendo, entre otras:

- RAG
- Intención
- DIN
- DEA
- RAG + Intención
- Intención + DIN + DEA
- RAG + Intención + DIN + DEA
- RAG + Memoria + Intención + DIN + DEA (arquitectura completa)

Cada configuración fue ejecutada sobre las mismas 53 consultas gold, garantizando condiciones experimentales homogéneas.

IV-E. Métricas de evaluación

El desempeño de cada configuración se evaluó utilizando tres métricas complementarias, ampliamente aceptadas en la literatura Text-to-SQL y pertinentes para el contexto ERP.

IV-E1. Execution Accuracy (EX): Mide el porcentaje de consultas cuya ejecución retorna exactamente el mismo resultado que la consulta gold correspondiente, independientemente de la forma sintáctica del SQL. Esta métrica es especialmente relevante en entornos empresariales, donde la corrección semántica del resultado es prioritaria frente a la coincidencia textual [1], [5].

IV-E2. Component Matching (CM): Evalúa el grado de coincidencia entre componentes estructurales del SQL generado y el SQL gold, tales como:

- Tablas utilizadas
- Columnas seleccionadas
- Operaciones de agregación
- Cláusulas de filtrado y agrupación

Esta métrica permite identificar errores parciales que no siempre se reflejan en la ejecución final, proporcionando una visión más granular del comportamiento del modelo.

IV-E3. Tiempo de respuesta (Time-to-Answer, TTA): Corresponde al tiempo total transcurrido desde que el usuario formula la consulta en lenguaje natural hasta que el sistema retorna el resultado final. Esta métrica es crítica en sistemas ERP, donde la latencia impacta directamente la experiencia del usuario y la viabilidad operativa de la solución [7], [8].

IV-F. Procedimiento experimental

El procedimiento seguido para cada configuración fue el siguiente:

1. Selección de una configuración específica de componentes.
2. Ejecución secuencial de las 53 consultas gold bajo dicha configuración.
3. Registro automático del SQL generado, resultado de ejecución, componentes estructurales y tiempo de respuesta.
4. Cálculo agregado de las métricas EX, CM y TTA.
5. Repetición del proceso para las 31 configuraciones definidas.

Este procedimiento garantiza comparabilidad directa entre configuraciones y permite analizar tanto el impacto individual de cada componente como sus efectos combinados.

IV-G. Análisis del impacto de componentes

Finalmente, los resultados obtenidos permiten realizar un análisis de impacto por componente mediante:

- Comparación directa entre configuraciones que difieren en un único componente.
- Identificación de sinergias entre módulos (por ejemplo, RAG + descomposición).
- Evaluación de compromisos (trade-offs) entre precisión y tiempo de respuesta.

Este análisis constituye la base empírica para determinar qué componentes son esenciales, cuáles son complementarios y en qué escenarios su inclusión resulta más beneficiosa, aportando evidencia experimental sólida para el diseño de arquitecturas Text-to-SQL en sistemas ERP.

IV-H. Referencia al anexo del conjunto de consultas

Con el fin de preservar la claridad del capítulo metodológico sin sacrificar trazabilidad ni reproducibilidad, el detalle completo del conjunto de consultas —incluyendo la pregunta en lenguaje natural, la clasificación por complejidad, la descomposición semántica, las tablas y columnas relevantes del esquema y la consulta SQL de referencia— se presenta en el Anexo A.

V. RESULTADOS EXPERIMENTALES Y DISCUSIÓN

En este capítulo se presentan los resultados del estudio experimental realizado mediante un análisis de ablación sobre distintas configuraciones arquitectónicas del sistema de transformación de lenguaje natural a SQL propuesto. Todas las configuraciones fueron evaluadas bajo condiciones controladas sobre un conjunto fijo de 53 preguntas de referencia, lo que permite comparar de manera directa el efecto individual y combinado de cada módulo sobre el desempeño del sistema.

El análisis se estructura en torno a cuatro dimensiones complementarias: (i) la calidad estructural del SQL generado, (ii) la exactitud por ejecución, (iii) la robustez ante errores considerando mecanismos de corrección, y (iv) la capacidad real de generación correcta desde el primer intento, sin recurrir a autocorrección. Esta descomposición permite evaluar no solo si el sistema logra producir consultas funcionales, sino también cómo y bajo qué condiciones se alcanza dicho desempeño.

Para ello, se emplean métricas consolidadas en la literatura de Text-to-SQL. En particular, se reporta el promedio del F1-score de Component Matching para los componentes SELECT, WHERE, GROUP BY y KEYWORDS, con el fin de medir el grado de alineamiento estructural entre el SQL generado y el SQL de referencia. Adicionalmente, se utiliza Execution Accuracy, que evalúa la corrección semántica de la consulta a partir del resultado

de su ejecución. Finalmente, se incorporan dos métricas orientadas a robustez: SIN ERRORES, que cuantifica el éxito considerando mecanismos de reparación durante la ejecución, y SIN_AUTO_CORRECCION, que estima la proporción de consultas correctamente generadas desde el primer intento. En conjunto, estas métricas permiten caracterizar el desempeño del sistema desde una perspectiva estructural, funcional y operativa.




Figura 2. Comparación entre Component Matching y Execution Accuracy para distintas configuraciones arquitectónicas. Esta gráfica permite visualizar que un alto Component Matching no garantiza, por sí solo, una ejecución correcta del SQL.

Asimismo, se observa que configuraciones con diferentes combinaciones de módulos pueden alcanzar valores similares de Component Matching, aun cuando su desempeño en ejecución difiere significativamente. Este resultado sugiere que una alta correspondencia estructural, si bien es una condición necesaria, no garantiza por sí sola la generación de consultas SQL funcionales. La Figura 2 ilustra claramente esta disociación entre calidad estructural y corrección funcional.

V-A. Calidad estructural del SQL (Component Matching)

Los resultados correspondientes a la métrica de Component Matching muestran que la mayoría de las configuraciones evaluadas alcanzan altos niveles de correspondencia estructural, especialmente en los componentes SELECT y WHERE, donde los valores promedio de F1-score superan frecuentemente el 85 %. Este comportamiento indica que el sistema es capaz de identificar de forma consistente las columnas relevantes y las condiciones de filtrado implícitas o explícitas en las preguntas formuladas en lenguaje natural.

En contraste, el componente GROUP BY presenta valores sistemáticamente inferiores en comparación con SELECT y WHERE. Esta tendencia se mantiene a lo largo de todas las configuraciones evaluadas y es consistente con observaciones previas en la literatura, donde las operaciones

de agregación suelen encontrarse implícitas en el lenguaje natural y requieren un mayor nivel de inferencia semántica y estructural. En particular, la correcta identificación de la clave de agrupación resulta más sensible a ambigüedades del dominio y a la necesidad de conocimiento contextual adicional.

V-B. Exactitud de ejecución (Execution Accuracy)

La métrica de Execution Accuracy revela diferencias sustanciales entre las configuraciones arquitectónicas evaluadas. En particular, se observa que algunas configuraciones que presentan altos valores de Component Matching experimentan una caída significativa en exactitud por ejecución, lo que evidencia que la correcta identificación de componentes estructurales no siempre se traduce en consultas semánticamente correctas y ejecutables.

Un caso representativo es la configuración [Intención + DIN + DEA], que alcanza valores elevados de F1-score en el componente WHERE, pero obtiene una Execution Accuracy del 37,74 %. Este resultado indica que, aun cuando el razonamiento estructural es adecuado, la ausencia de un mecanismo explícito de grounding contextual limita la capacidad del sistema para seleccionar tablas, columnas o relaciones correctas dentro de un esquema complejo.


Por el contrario, la configuración [RAG + DIN + DEA] alcanza el mejor desempeño global, con una Execution Accuracy superior al 81 %, superando incluso configuraciones más complejas que incorporan módulos adicionales como Memoria o clasificación explícita de Intención. Este comportamiento sugiere que la recuperación contextual del esquema cumple un rol determinante en la traducción efectiva de la intención del usuario a consultas SQL ejecutables, particularmente en entornos empresariales con esquemas extensos.

En conjunto, estos resultados evidencian una brecha clara entre calidad estructural y corrección funcional, resaltando la necesidad de evaluar explícitamente la ejecución para caracterizar el desempeño real de sistemas Text-to-SQL. La Figura 3 presenta de manera visual las diferencias de rendimiento entre las configuraciones evaluadas.

V-C. Robustez ante errores considerando autocorrección (SIN ERRORES)

La métrica SIN ERRORES evalúa la capacidad del sistema para producir una consulta funcional considerando la presencia de mecanismos de ajuste y corrección automática durante la generación y ejecución del SQL. Los resultados muestran que la mayoría de las configuraciones que incorporan RAG alcanzan valores cercanos o iguales al 100 %, lo que evidencia una alta robustez frente a errores sintácticos, referencias incorrectas o fallos menores en la formulación de la consulta.


Este comportamiento indica que la recuperación aumentada por contexto no solo mejora la comprensión semántica de la consulta, sino que también actúa como un mecanismo de mitigación de errores, reduciendo la probabilidad de fallos no recuperables durante la ejecución. En particular,



Parámetros	SELECT	WHERE	GROUP BY	EXECUTION
[Rag],[Memoria],[Din],[Dea]	72,31%	86,48%	59,12%	73,58%
[Intención],[Din],[Dea]	75,92%	90,57%	57,23%	37,74%
[Rag],[Din],[Dea]	78,50%	93,65%	67,92%	81,13%
[Rag]	69,45%	77,04%	52,83%	60,38%

Figura 3. Exactitud de ejecución (Execution Accuracy) para las distintas configuraciones arquitectónicas evaluadas. Se observan diferencias sustanciales entre configuraciones, destacando el rol determinante de la recuperación contextual del esquema (RAG) en la generación de consultas SQL ejecutables.

el acceso a descripciones del esquema y ejemplos relevantes parece facilitar la corrección iterativa de errores comunes, como joins incompletos o uso incorrecto de agregaciones.



Parámetros	EXECUTION	SIN ERRORES	KEYWORDS
[Intención],[Din],[Dea]	37,74%	54,72%	90,42%
[Rag],[Din],[Dea]	81,13%	98,11%	91,60%
[Rag],[Dea]	69,81%	100,00%	91,97%
[Rag],[Memoria]	67,92%	98,11%	87,56%

Figura 4. Robustez del sistema considerando mecanismos de autocorrección (SIN ERRORES). Las configuraciones que incorporan RAG alcanzan valores cercanos al 100 %, evidenciando alta robustez frente a errores sintácticos y referencias incorrectas mediante corrección iterativa.

No obstante, esta métrica debe interpretarse con cautela, ya que no distingue entre consultas correctamente generadas desde el primer intento y aquellas que requieren múltiples iteraciones de corrección. En este sentido, valores elevados de SIN ERRORES pueden reflejar una robustez operativa, pero no necesariamente una alta calidad inicial en la generación del SQL. La Figura 4 muestra cómo las


configuraciones con RAG logran alta robustez mediante mecanismos de corrección automática.

V-D. Capacidad real de generación sin autocorrección (SIN_AUTO_CORRECCION)

La métrica SIN_AUTO_CORRECCION permite evaluar de manera más estricta la capacidad del sistema para generar consultas SQL correctas desde el primer intento, sin depender de mecanismos de reparación automática. Esta métrica revela diferencias sustanciales entre configuraciones que, de otro modo, presentan valores similares en SIN ERRORES.

Los resultados muestran que configuraciones basadas únicamente en RAG o en modelado de Intención dependen fuertemente de la autocorrección, alcanzando valores inferiores al 30 % en generación correcta inicial. Este comportamiento indica que, si bien dichas configuraciones pueden eventualmente producir consultas funcionales, lo hacen a costa de múltiples iteraciones de corrección.

En contraste, la configuración [RAG + DIN + DEA] alcanza un valor cercano al 89 % en SIN_AUTO_CORRECCION, lo que evidencia una alta capacidad de generación correcta directa. Este resultado sugiere que la combinación de recuperación contextual con descomposición y razonamiento orientado a la ejecución permite al sistema formular consultas más precisas desde el inicio, reduciendo la dependencia de ciclos de corrección posteriores.



Parámetros	EXECUTION	SIN ERRORES	SIN_AUTO_CORRECCION
[Intención],[Din],[Dea]	37,74%	54,72%	33,96%
[Rag],[Din],[Dea]	81,13%	98,11%	88,68%
[Rag],[Intención]	56,60%	98,11%	9,43%
[Rag]	60,38%	100,00%	18,87%

Figura 5. Comparación de la capacidad de generación sin autocorrección (SIN_AUTO_CORRECCION) entre configuraciones. Se evidencia que la configuración [RAG + DIN + DEA] alcanza valores cercanos al 89 %, mientras que configuraciones basadas únicamente en RAG o Intención dependen fuertemente de mecanismos de corrección iterativa.

Esta métrica resulta clave para diferenciar entre robustez aparente y capacidad real de generación, especialmente en escenarios de producción donde la latencia y la previsibilidad del sistema son factores críticos. La Figura 5 ilustra claramente las diferencias en la capacidad de generación directa entre las distintas configuraciones evaluadas.

V-E. Validación de los módulos de Intensión y Memoria en escenarios conversacionales

Además del análisis cuantitativo, se realizó una validación cualitativa orientada a evaluar el comportamiento de los módulos de Intensión y Memoria en escenarios conversacionales multi-turno, característicos de la interacción natural entre usuarios y sistemas ERP.

En sistemas de transformación de lenguaje natural a SQL orientados a la interacción conversacional, no todas las entradas del usuario constituyen solicitudes ejecutables. Expresiones iniciales como saludos, preguntas genéricas o referencias incompletas carecen de la información semántica necesaria para generar una consulta válida. En este contexto, la ejecución inmediata de una consulta SQL no solo resulta innecesaria, sino potencialmente incorrecta.

Para abordar este problema, el sistema incorpora un módulo de Intensión, cuya función principal es determinar si una entrada del usuario contiene información suficiente para ser interpretada como una solicitud ejecutable. Este módulo actúa como una capa de validación semántica previa a la generación de SQL, evitando intentos de ejecución cuando la intención del usuario es ambigua, incompleta o puramente conversacional.

No obstante, en escenarios reales de interacción humano-sistema, la información requerida para ejecutar una consulta puede encontrarse distribuida a lo largo de múltiples turnos de diálogo. En estos casos, el módulo de Memoria desempeña un rol complementario, permitiendo conservar y recuperar el contexto semántico generado en interacciones previas. La combinación de ambos módulos habilita la reconstrucción de solicitudes completas a partir de fragmentos conversacionales, sin exigir que el usuario formule explícitamente una consulta totalmente especificada en un único mensaje.

V-E1. Ejemplo ilustrativo de escenario multi-turno: Para ilustrar el funcionamiento coordinado de ambos módulos, se presenta el siguiente caso de uso representativo:

Turno 1 – Usuario: “Hola, ¿me puedes ayudar con los productos?”

- *Intención detectada:* No ejecutable
- *Acción del sistema:* No se genera SQL

En este primer turno, el módulo de Intensión determina que la entrada no corresponde a una solicitud ejecutable, dado que no se especifica ninguna acción concreta ni criterios de selección. En consecuencia, el sistema no genera ni ejecuta una consulta SQL, evitando así una interpretación errónea de la intención del usuario.

Turno 2 – Usuario: “Dame el nombre de los primeros 5”

- *Memoria recupera el contexto:* productos
- *Intención detectada:* Ejecutable
- *Consulta implícita reconstruida:* “Obtener el nombre de los primeros 5 productos”
- *Acción del sistema:* Generación y ejecución del SQL

En este segundo turno, el módulo de Memoria recupera el contexto semántico previamente mencionado (productos). Con esta información, el módulo de Intensión evalúa que la

combinación de ambos turnos constituye una solicitud completa y ejecutable. El sistema puede entonces reconstruir implícitamente la consulta como “Obtener el nombre de los primeros cinco productos” y proceder a la generación y ejecución del SQL correspondiente.

Este mecanismo permite prevenir ejecuciones inválidas o ambiguas, al tiempo que soporta interacciones progresivas y naturales, donde el usuario no necesita formular una consulta completa en un único turno. De esta forma, los módulos de Intensión y Memoria no deben evaluarse exclusivamente por métricas de ejecución, sino por su capacidad de regular cuándo es semánticamente válido ejecutar una consulta, contribuyendo a la confiabilidad global del sistema en escenarios conversacionales reales.

APÉNDICE

A. Descripción general del conjunto de consultas

Este anexo presenta el conjunto de consultas de referencia (*gold queries*) utilizado para la evaluación del sistema Text-to-SQL propuesto. Dicho conjunto fue construido manualmente a partir de escenarios reales de uso del ERP Fail Fast, con el objetivo de reflejar preguntas típicas formuladas por usuarios empresariales sin conocimientos técnicos en SQL.

Cada consulta documentada en este anexo incluye:

- La formulación original de la pregunta en lenguaje natural.
- La clasificación por nivel de complejidad (baja, media o alta).
- La descomposición semántica empleada para su resolución.
- La identificación de las tablas y columnas relevantes del esquema.
- La consulta SQL de referencia (*gold standard*), validada contra la base de datos real del sistema.

Este nivel de detalle permite asegurar trazabilidad metodológica, facilitar la reproducibilidad del experimento y habilitar análisis posteriores sobre patrones de error y comportamiento del sistema.

B. Consultas de complejidad baja

Las consultas de complejidad baja se caracterizan por involucrar una única tabla o un conjunto reducido de columnas, con filtros directos y, en algunos casos, operaciones simples de ordenamiento o conteo. Este tipo de consultas representa solicitudes frecuentes de tipo informativo, como la obtención de registros recientes, conteos básicos o la recuperación de atributos específicos de una entidad.

Su inclusión permite evaluar la capacidad del sistema para manejar correctamente escenarios elementales sin introducir errores innecesarios en la selección de tablas, columnas o condiciones de filtrado.

C. Consultas de complejidad media

Las consultas de complejidad media involucran operaciones de agregación (**SUM**, **COUNT**), cláusulas de agrupamiento

Tabla A.1. Consultas de complejidad baja

ID	Consulta en lenguaje natural	Esquema involucrado	SQL de referencia (Gold)
42	Suminístrame las primeras 3 sucursales que se han creado en el sistema, solo requiero el nombre y la fecha de creación.	core.branch_office (name, created_at)	SELECT name, created_at FROM core.branch_office WHERE member_id = \$1 AND audit_status <> '0' ORDER BY created_at ASC LIMIT 3;
43	Give me the first branch office of core module, I only need name and created date ordered by created date ascending.	core.branch_office (name, created_at)	SELECT name, created_at FROM core.branch_office WHERE member_id = \$1 AND audit_status <> '0' ORDER BY created_at ASC LIMIT 3;
45	¿Cuántas categorías de nombre "VOLQUETA" tenemos en este momento?	core.category (name)	SELECT COUNT(id) FROM core.category WHERE name = 'VOLQUETA' AND audit_status <> '0' AND member_id = \$1;
47	¿Cuál es el nombre de la categoría con código 1601?	core.category (name, code)	SELECT name FROM core.category WHERE member_id = \$1 AND code = '1601' AND audit_status <> '0';

Figura 6. Consultas de complejidad baja utilizadas en la evaluación

(GROUP BY) y, en algunos casos, combinaciones simples entre tablas. Estas consultas requieren una identificación explícita de la clave de agrupación y la correcta aplicación del contexto multi-tenant del sistema.

Este nivel de complejidad es representativo de reportes operativos y financieros comunes en sistemas ERP reales.

Tabla A.2. Consultas de complejidad media

ID	Consulta en lenguaje natural	Descomposición semántica	Esquema involucrado	SQL de referencia (Gold)
1	Para mi empresa, quiero ver por cada valor distinto de la columna user_member_id la suma del campo bal_account registrada en compras - manager, y cuántos registros tiene cada user_member_id.	1) Identificar tabla y campo numérico. 2) Agrupar por user_member_id. 3) Agregar filter member_id. 4) Calcular SUM y COUNT.	purchase.manager (user_member_id, bal_account)	SELECT user_member_id, SUM(bal_account) AS total_bal_account, COUNT(*) AS registros FROM purchase.manager WHERE member_id = \$1 AND audit_status <> '0' GROUP BY user_member_id;
6	Para mi empresa, quiero ver por cada valor distinto de la columna account_id la suma del campo balance registrada en treasury - bank account, y cuántos registros tiene cada account_id.	Identificación de agregación monetaria y agrupación por cuenta contable.	treasury.bank_account (account_id, balance)	SELECT account_id, SUM(balance) AS total_balance, COUNT(*) AS registros FROM treasury.bank_account WHERE member_id = \$1 AND audit_status <> '0' GROUP BY account_id;
40	Indícame los últimos 5 productos que se han creado, solo requiero el nombre y la descripción.	Ordenamiento por fecha de creación descendente y límite.	inventory.product (name, description, created_at)	SELECT name, description FROM inventory.product WHERE member_id = \$1 AND audit_status <> '0' ORDER BY created_at DESC LIMIT 5;
51	Indícame la cantidad exacta de pedidos elaborados junto con la sumatoria del subtotal y del total.	Agrupación global sin agrupamiento.	order.order (subtotal, total)	SELECT COUNT(id), SUM(subtotal), SUM(total) FROM "order" WHERE member_id = \$1 AND audit_status <> '0';

Figura 7. Consultas de complejidad media utilizadas en la evaluación

D. Consultas de complejidad alta

Las consultas de complejidad alta requieren combinaciones entre múltiples tablas pertenecientes a distintos módulos del ERP, así como razonamiento multietapa para integrar información distribuida en el esquema. En estos casos, la resolución de la consulta implica descomponer la pregunta original en sub-tareas, resolver dependencias entre entidades y aplicar agregaciones sobre los resultados combinados.

Tabla A.3. Consultas de complejidad alta

ID	Consulta en lenguaje natural	Estrategia de descomposición	Esquemas involucrados	SQL de referencia (Gold)
21	Necesito un resumen combinando integration - member credential y transporte - service order detail vehicle, agrupando por empresa y mostrando la suma del campo correspondiente y el número de registros.	Join multi-tabla por member_id + agregación.	integration.member_credential national_transport_service_order_detail_vehicle	Consulta con JOIN por member_id, SUM y COUNT.
22	Necesito combinar transporte - service order con compras - order y obtener, para cada market_exchange_rate_id, la suma del total y el número de registros.	Join por clave de mercado + agregación.	national_transport_service_order purchase.order	Consulta con JOIN, GROUP BY market_exchange_rate_id.
52	Cantidad de pedidos elaborados junto con subtotal y total, agrupados por cliente, mostrando nombre y documento.	Join order + customer_detail + agrupación.	order.order account_receivable_customer_detail	SELECT customer.name, COUNT(order_id), SUM(subtotal), SUM(total) ... GROUP BY customer_id;

Nota: En consultas de alta complejidad, el SQL de referencia puede abreviarse cuando su extensión completa afecta la legibilidad del anexo. En todos los casos, la versión completa fue utilizada durante la evaluación experimental.

Figura 8. Consultas de complejidad alta utilizadas en la evaluación

Nota: En las consultas de mayor complejidad, el SQL de referencia puede presentarse de forma abreviada cuando su extensión completa afecta la legibilidad del anexo. En todos los casos, la versión completa fue utilizada durante la evaluación experimental.

E. Observaciones metodológicas

Las consultas incluidas en este anexo fueron diseñadas para cubrir patrones frecuentes de interacción en sistemas ERP reales, tales como agregaciones financieras, consultas multi-tabla, análisis temporal y reportes operativos. Su documentación detallada permite complementar la metodología experimental descrita en el Capítulo IV y facilitar la replicación del estudio.

REFERENCIAS

- [1] T. Yu et al., "Spider: A large-scale human-labeled dataset for complex and cross-domain semantic parsing and text-to-SQL task," in *Proc. EMNLP*, Brussels, Belgium, 2018, pp. 3911–3921.
- [2] T. Scholak, N. Schucher, and D. Bahdanau, "PICARD: Parsing incrementally for constrained auto-regressive decoding from language models," in *Proc. EMNLP*, Punta Cana, Dominican Republic, 2021, pp. 9895–9901.
- [3] M. Pourreza and D. Rafiei, "DIN-SQL: Decomposed in-context learning of text-to-SQL with self-correction," in *Proc. NeurIPS*, New Orleans, LA, USA, 2023, pp. 23–35.
- [4] Y. Gan et al., "Natural SQL: Making SQL easier to infer from natural language specifications," in *Proc. EMNLP*, Online, 2021, pp. 2030–2042.
- [5] J. Hong et al., "BIRD: A big bench for large-scale database grounded text-to-SQL evaluation," in *Proc. NeurIPS*, Vancouver, Canada, 2024, pp. 45–58.
- [6] K. Luo et al., "Schema linking for text-to-SQL: A survey and new benchmark," *ACM Trans. Database Syst.*, vol. 50, no. 2, pp. 1–28, Mar. 2025.
- [7] P. Shi et al., "A comprehensive survey of large language models for text-to-SQL," *ACM Comput. Surv.*, vol. 58, no. 1, pp. 1–35, Jan. 2025.
- [8] H. Liu et al., "Text-to-SQL in the era of large language models: A comprehensive survey," *IEEE Trans. Knowl. Data Eng.*, vol. 37, no. 3, pp. 1123–1140, Mar. 2025.
- [9] S. Hong et al., "Recent advances in neural text-to-SQL: A comprehensive review," *Artif. Intell. Rev.*, vol. 58, no. 4, pp. 891–925, Apr. 2025.
- [10] F. Li and H. V. Jagadish, "Constructing an interactive natural language interface for relational databases," *Proc. VLDB Endow.*, vol. 8, no. 1, pp. 73–84, Sep. 2014.
- [11] Y. Yaghmazadeh et al., "SQLizer: Query synthesis from natural language," *Proc. ACM Program. Lang.*, vol. 1, no. OOPSLA, pp. 63:1–63:26, Oct. 2017.
- [12] L. Dong and M. Lapata, "Language to logical form with neural attention," in *Proc. ACL*, Berlin, Germany, 2016, pp. 33–43.
- [13] H. Li et al., "ResdsQL: Decoupling schema linking and skeleton parsing for text-to-SQL," in *Proc. AAAI*, Washington, DC, USA, 2023, pp. 13067–13075.
- [14] J. Huang et al., "Large language models for text-to-SQL: A survey of methods and evaluation," *Found. Trends Databases*, vol. 12, no. 3-4, pp. 234–298, 2024.
- [15] C. Xie et al., "DEA-SQL: Decomposition for enhancing attention in text-to-SQL," in *Proc. ICLR*, Vienna, Austria, 2024, pp. 1–15.
- [16] Y. Li et al., "A comprehensive evaluation of large language models on text-to-SQL tasks," in *Proc. ICML*, Honolulu, HI, USA, 2024, pp. 2891–2905.
- [17] X. Wang et al., "MAC-SQL: Multi-agent collaborative framework for text-to-SQL," in *Proc. ICLR*, Kigali, Rwanda, 2025, pp. 1–16.
- [18] L. Han et al., "GraphRAG: Enhancing retrieval-augmented generation with knowledge graphs," *ACM Trans. Inf. Syst.*, vol. 43, no. 2, pp. 1–24, Apr. 2025.
- [19] S. Aparicio et al., "Natural language to SQL in low-code platforms," arXiv preprint arXiv:2308.15239, 2023.
- [20] L. Dou et al., "Towards knowledge-intensive text-to-SQL semantic parsing with formulaic knowledge," in *Proc. EMNLP*, Abu Dhabi, UAE, 2022, pp. 5240–5253.
- [21] D. Gao et al., "DAIL-SQL: Dynamic few-shot in-context learning for text-to-SQL," arXiv preprint arXiv:2403.10072, 2024.
- [22] J. Lee, S. Kim, and H. Cho, "MCS-SQL: Multiple-choice selection with multi-prompts for robust text-to-SQL generation," arXiv preprint arXiv:2403.08764, 2024.

- [23] M. Talei, S. Cho, and T. Kim, “CHESS: Contextual harnessing for efficient SQL synthesis,” arXiv preprint arXiv:2404.03919, 2024.
- [24] H. Zhang et al., “ACT-SQL: In-context learning for text-to-SQL with automatically-generated chain-of-thought,” in *Findings of EMNLP*, Singapore, 2023, pp. 3501–3532.
- [25] D. Rai et al., “Improving generalization in language model-based text-to-SQL semantic parsing: Two simple semantic boundary-based techniques,” in *Proc. ACL*, Toronto, Canada, 2023, pp. 150–160.
- [26] A. Singh et al., “A survey of large language model-based generative AI for text-to-SQL: Benchmarks, applications, use cases, and challenges,” arXiv preprint arXiv:2412.05208, 2025.
- [27] X. Zhu et al., “Large language models for text-to-SQL: A comprehensive evaluation,” *Comput. Linguist.*, vol. 50, no. 4, pp. 789–825, Dec. 2024.